

## 第二章作业

一、多分类问题的四个反向传播方程（损失函数为交叉熵损失函数，使用 ReLU 激活函数）

一、多分类问题的四个反向传播方程

① 输出层使用 softmax 函数:  $a_i^L = \frac{e^{z_i^L}}{\sum_{j=1}^K e^{z_j^L}}$

$a_i^L$  表示输出层经过 softmax 后的值

$z_i^L$  表示 softmax 输入的值

$K$  表示输出层神经元个数

损失函数为交叉熵损失函数:

$$Loss = E = - \sum_{j=1}^K y_j \ln a_j^L$$

$y$  为 label 是 one-hot 向量

$y_j$  表示  $y$  的第  $j$  个值

$\because y$  为 one-hot 向量  $\therefore$  仅有一个值为 1, 其余为 0

假设对于  $y$  有  $y_i = 1$ , 则  $y_j = 0$ ,  $j$  为除  $i$  的其余所有值

$$E = -\ln a_i^L = -z_i^L + \ln \sum_{j=1}^K e^{z_j^L}$$

设  $\delta^L$  为中间变量保存第  $L$  层误差,  $\delta^L$  则为输出层误差,  $\delta_j^L$  表示输出层误差第  $j$  个

$$\delta_i^L = \frac{\partial E}{\partial z_i^L} = -1 + \frac{e^{z_i^L}}{\sum_{j=1}^K e^{z_j^L}} = -1 + a_i^L$$

同理

$$\delta_j^L = \frac{\partial E}{\partial z_j^L} = 0 + a_j^L$$

$$\Rightarrow \delta_j^L = a_j^L - y_j, j \text{ 为 } 1 \dots K \text{ 作遍值}$$

$\Downarrow$  向量表达式

$$\delta^L = a^L - y$$

$\therefore (BP_1)$  输出层误差的向量表达式为  $\delta^L = a^L - y$

② (BP2) 使用下一层的误差  $\delta^{L+1}$  表示当前层误差  $\delta^L$

除输出层外, 中间隐层的激活函数使用 ReLU 激活函数 即  $\sigma(z) = \begin{cases} 0, & z \leq 0 \\ z, & z > 0 \end{cases}$

$$z_j^{L+1} = \sum_{k=1}^K W_{jk}^L a_k^L + b_j^L$$

$z_j^{L+1}$  表示第  $L+1$  层第  $j$  个神经元  $z$  值

$W_{jk}^L$  表示第  $L$  层第  $k$  个神经元发送到第  $L+1$  层第  $j$  个神经元的权值

$b_j^L$  表示第  $L$  层发送到第  $L+1$  层第  $j$  个神经元的偏置

$$\delta_j^L = \frac{\partial E}{\partial z_j^L} = \sum_{k=1}^K \frac{\partial E}{\partial z_k^{L+1}} \frac{\partial z_k^{L+1}}{\partial z_j^L}$$

$$= \sum_{k=1}^K \delta_k^{L+1} \cdot \frac{\partial z_k^{L+1}}{\partial z_j^L}$$

$$z_k^{L+1} = \sum_{t=1}^L W_{kt}^L a_t^L + b_k^L = \sum_{t=1}^L W_{kt}^L \sigma(z_t^L) + b_k^L$$

这里  $t$  表示  $L$  层的神经元

这里  $k$  表示  $L+1$  层的第  $k$  个神经元

$$\frac{\partial z_k^{L+1}}{\partial z_j^L} = W_{kj}^L \cdot \sigma'(z_j^L)$$

$\Rightarrow$  向量表达式

$$\delta^L = (W^{L+1} \delta^{L+1}) \odot \sigma'(z^L) \quad (BP2)$$

$$\Rightarrow \delta_j^L = \sum_{k=1}^K \delta_k^{L+1} \cdot W_{kj}^L \sigma'(z_j^L)$$

② (BP3) 代价函数关于偏置 bias 的偏导  $\frac{\partial E}{\partial b^{L-1}}$

$$z_j^L = \sum_{k=1} W_{jk}^{L-1} a_k^{L-1} + b_j^{L-1}$$

$$\frac{\partial E}{\partial b_j^{L-1}} = \frac{\partial E}{\partial z_j^L} \cdot \frac{\partial z_j^L}{\partial b_j^{L-1}} = \delta_j^L \cdot 1 = \delta_j^L$$

$$\Rightarrow \frac{\partial E}{\partial b^{L-1}} = \delta^L$$

④ (BP4) 代价函数关于权重的偏导  $\frac{\partial E}{\partial W^{L-1}}$

$$z_j^L = \sum_{k=1} W_{jk}^{L-1} a_k^{L-1} + b_j^{L-1}$$

$$\frac{\partial E}{\partial W_{jk}^{L-1}} = \frac{\partial E}{\partial z_j^L} \cdot \frac{\partial z_j^L}{\partial W_{jk}^{L-1}}$$

$$= \delta_j^L \cdot a_k^{L-1}$$

$$\frac{\partial E}{\partial W^{L-1}} = a^{L-1} (\delta^L)^T \quad (\text{BP4})$$

$$\frac{\partial E}{\partial W_j^{L-1}} = a^{L-1} \cdot \delta_j^L$$

## 二、手写数字识别

### 1、代码解析

(1) mnist\_reader.py 读取 mnist.pkl.gz 中数据并将其转换为常用格式

```
1. import pickle
2. import gzip
3. import numpy as np
4. from PIL import Image
5. import matplotlib.pyplot as plt
6.
7.
8. # 解压数据集并读取
9. def load_data():
10.     file = gzip.open('mnist.pkl.gz', 'rb')
11.     train_data, validation_data, test_data = pickle.load(file, encoding="bytes")
12.     # train_data (50000*784, 5000*1)
13.     # print(train_data[0].shape)
14.     file.close()
15.     return train_data, validation_data, test_data
16.
17.
18. # 处理读取的初始数据，转换为常用格式
19. def raw_data_process():
20.     raw_tr_data, raw_val_data, raw_te_data = load_data()
21.     # 训练集
22.     train_inputs = [np.reshape(x, (784, 1)) for x in raw_tr_data[0]] # input 784*50000
23.     train_labels = [one_hot_transform(x) for x in raw_tr_data[1]] # label 10*50000
24.     # input 和 label 一一对应
25.     train_data = list(zip(train_inputs, train_labels))
26.     # print("训练集大小: {}".format(len(train_labels)))
27.     # 验证集
28.     validation_inputs = [np.reshape(x, (784, 1)) for x in raw_val_data[0]] # 784*10000
29.     validation_labels = [one_hot_transform(x) for x in raw_val_data[1]] # 输出 10*10000
30.     validation_data = list(zip(validation_inputs, validation_labels))
31.     # 测试集
32.     test_inputs = [np.reshape(x, (784, 1)) for x in raw_te_data[0]] # 784*10000
33.     test_labels = [one_hot_transform(x) for x in raw_te_data[1]] # 输出 10*10000
34.     test_data = list(zip(test_inputs, test_labels))
```

```

35.     return train_data, validation_data, test_data
36.
37.
38. # 生成 one-hot 向量
39. def one_hot_transform(j):
40.     # shape 10*1
41.     label_y = np.zeros((10, 1))
42.     label_y[j] = 1.0
43.     return label_y
44.
45.
46. # 使用 PIL 图像 api, 将图像显示出来 784*1 28*28
47. def show_image(vector):
48.     vector.resize((28, 28))
49.     img = Image.fromarray(np.uint8(vector * 255)).convert("1") # 二值化
50.     plt.imshow(img)
51.     plt.show()
52.
53.
54. if __name__ == '__main__':
55.     train_data, validation_data, test_data = raw_data_process()
56.     # train_data[0] 784*50000 train_data[1] 10*50000
57.     # print(train_data[0][1]) # 784*1
58.     show_image(train_data[0][1])

```

(2) network.py 构建输入层-中间隐层-输出层网络结构, 实现前向传播、反向传播和随机梯度下降代码

```

1. import numpy as np
2. import random
3.
4.
5. # ReLU 激活函数
6. def relu(z):
7.     z[z < 0] = 0
8.     return z
9.
10.
11. # ReLU 激活函数的导数
12. def d_relu(z):
13.     z[z > 0] = 1
14.     z[z <= 0] = 0
15.     return z
16.
17.

```

```

18. # softmax 函数
19. def softmax(z):
20.     t = np.exp(z)
21.     a = np.nan_to_num(np.exp(z) / np.sum(t))
22.     return a
23.
24.
25. # 神经网络的类
26. class Network(object):
27.     # 构造函数初始化网络
28.     def __init__(self, sizes): # sizes(784, 15, 10) 输入 784 隐层 15 输出 10
29.         # 神经网络层数
30.         self.layer_nums = len(sizes)
31.         self.sizes = sizes
32.         # randn(j, i) 可以生成 y 行 x 列的随机数矩阵, 是均值为 0, 标准差为 1 的高斯分布
33.         # bias 向量维度由下一层神经元个数决定 15*1 10*1
34.         self.biases = [np.random.randn(i, 1) for i in sizes[1:]]
35.         # weights 矩阵维度由输入层和下一层共同决定, 15*784 10*15 w^T 方便运算
36.         self.weights = [np.random.randn(j, i) for i, j in zip(sizes[:-1], sizes[1:])] # [784 15] [15,10]
37.
38.     # 前向传播
39.     # z1=W1^T*x+B1 a1 = relu(z1) z2=W2^T*a1+B2 a2= softmax(z2) a2=y^
40.     def forward(self, a):
41.         # 中间隐藏层的激活函数选择 relu, 输出层的激活函数为 softmax
42.         num_forward = 1
43.         for w, b in zip(self.weights, self.biases):
44.             z = np.dot(w, a)+b
45.             if num_forward < (self.layer_nums - 1): # relu 激活
46.                 a = relu(z)
47.                 num_forward = num_forward + 1
48.             else:
49.                 a = softmax(z)
50.         return a
51.
52.     # 随机梯度下降(训练数据,迭代次数,batch 大小,学习率,是否有测试集)
53.     def SGD(self, train_data, epochs, mini_batch_size, learning_rate, test_data=None):
54.         # 迭代过程
55.         print("Training.....")
56.         n = len(train_data) # 训练数据大小
57.         for j in range(epochs):
58.             # 打乱训练集

```

```

59.         random.shuffle(train_data)
60.         # mini_batches 是分批后的 mini_batch 列表
61.         mini_batches = [train_data[k:k+mini_batch_size] for k in range(0
, n, mini_batch_size)]
62.         # 每个 mini_batch 都更新一次,重复整个数据集
63.         self.update_mini_batch(mini_batches, learning_rate)
64.         # 若有测试数据,则在屏幕上打印训练进度
65.         if test_data:
66.             len_test = len(test_data)
67.             correct_num = self.evaluate(test_data)
68.             print("Epoch{0}:{1}/{2}".format(j, correct_num, len_test))
69.         else:
70.             print("Epoch {0} complete:".format(j))
71.
72.     # 更新 mini_batch
73.     def update_mini_batch(self, mini_batches, learning_rate):
74.         for mini_batch in mini_batches:
75.             # 存储对于各个参数的偏导, 格式和 self.biases 和 self.weights 是一样
            的
76.             nabla_b = [np.zeros(b.shape) for b in self.biases]
77.             nabla_w = [np.zeros(w.shape) for w in self.weights]
78.             eta = learning_rate / len(mini_batch)
79.             # mini_batch 中的一个实例调用梯度下降得到各个参数的偏
            导 mini_batch(x,y)元组
80.             for x, y in mini_batch:
81.                 # 从一个实例得到的梯度
82.                 delta_nabla_b, delta_nabla_w = self.backprop(x, y) # 依次取
                    出 mini_batch 中的 (x,y)输入 backprop
83.                 # nabla_w,nabla_b 表示整个 mini_batch 所有训练样本的总代价函数梯
                    度
84.                 nabla_b = [nb + dnb for nb, dnb in zip(nabla_b, delta_nabla_
                    b)]
85.                 nabla_w = [nw + dnw for nw, dnw in zip(nabla_w, delta_nabla_
                    w)]
86.             # 每一个 mini_batch 更新一下参数
87.             self.biases = [b - eta * nb for b, nb in zip(self.biases, nabla_
                    b)]
88.             self.weights = [w - eta * nw for w, nw in zip(self.weights, nabl
                    a_w)]
89.
90.     # 反向传播(对于每一个实例)
91.     def backprop(self, x, y):
92.         # 生成权重矩阵形状和偏置矩阵形状的零矩阵用于存放每层的梯度
93.         nabla_b = [np.zeros(b.shape) for b in self.biases]

```

```

94.         nabla_w = [np.zeros(w.shape) for w in self.weights]
95.         # 前向传播
96.         activation = x # activation 存储激活值
97.         activations = [x] # 存储每层的激活值 a
98.         z_save = [] # 存储前向传播的 z
99.         current_layer = 1 # 当前层数
100.        for w, b in zip(self.weights, self.biases):
101.            z = np.dot(w, activation)+b
102.            z_save.append(z)
103.            # 最后一层使用 softmax,前几层使用 relu
104.            if current_layer < (self.layer_nums - 1):
105.                activation = relu(z)
106.                current_layer = current_layer + 1
107.            else:
108.                activation = softmax(z)
109.            activations.append(activation)
110.        # 计算 loss 反向传播
111.        delta = self.d_cost(activations[-1], y) # 输出层的 a^L
112.        nabla_b[-1] = delta
113.        nabla_w[-1] = np.dot(delta, activations[-2].transpose())
114.        # 倒数第二层开始求偏导
115.        for l in range(2, self.layer_nums):
116.            delta = np.dot(self.weights[-
117.                l+1].transpose(), delta)*d_relu(z_save[-l])
118.            nabla_b[-l] = delta
119.            nabla_w[-l] = np.dot(delta, activations[-l-1].transpose())
120.        return nabla_b, nabla_w
121.
122.        # 代价函数偏导
123.        def d_cost(self, output_activations, y): # 输出的激活值
124.            a, label_y, z^L
125.            return output_activations-y # 交叉熵代价函数 E = -
126.            ln(a^L) ai^L=softmax(zi^L) E 对 ai^L 求偏导
127.
128.        # 验证准确率
129.        def evaluate(self, test_data):
130.            # 神经网络的输出结果是输出层激活值最大的一个神经元所对应的结果, 使用
131.            numpy 的 argmax 方法来找到该输出层神经元的编号
132.            # 将测试得到的结果以二元组(神经网络判断结果,正确结果)形式存储
133.            test_result = [(np.argmax(self.forward(x)), np.argmax(y)) for (x, y
134.                ) in test_data]
135.            return sum(int(i == j) for (i, j) in test_result)

```



### (3) main.py 调用前两个 py 文件函数

```
1. # 实现一个手写数字识别程序
2. import mnist_reader
3. import network
4.
5.
6. # 主函数
7. if __name__ == '__main__':
8.     # 读取原始数据处理输出 训练集 验证集 测试集
9.     train_data, validation_data, test_data = mnist_reader.raw_data_process()
10.    # 初始化神经网络 (784, 15, 10)
11.    net = network.Network((784, 15, 10))
12.    # 训练神经网络
13.    epochs = 10 # 训练次数
14.    mini_batch_size = 10 # batch 大小
15.    learning_rate = 0.1 # 学习率
16.    net.SGD(train_data, epochs, mini_batch_size, learning_rate, test_data=test_data)
17.    # 测试神经网络
18.    print("Test times {0}: {1}/{2}(正确识别个数/训练总数)".format(0, net.evaluate(test_data), 10000))
```

## 2、实验结果

### (1) batch\_size = 10 learning\_rate = 0.1

```
D:\Python\anaconda\anaconda3\envs\pytorch_gpu\python.exe D:/Python/pycharm/pythonProject/numberRecognition/main.py
Training.....
Epoch0:7858/10000
Epoch1:8687/10000
Epoch2:8918/10000
Epoch3:8843/10000
Epoch4:9067/10000
Epoch5:9004/10000
Epoch6:9101/10000
Epoch7:9161/10000
Epoch8:9095/10000
Epoch9:9190/10000
Test times 0: 9190/10000(正确识别个数/训练总数)

Process finished with exit code 0
```

### (2) batch\_size = 10 learning\_rate = 0.5 学习率过大，局部最优解

```
D:\Python\anaconda\anaconda3\envs\pytorch_gpu\python.exe D:/Python/pycharm/pythonProject/numberRecognition/main.py
Training.....
Epoch0:5888/10000
Epoch1:6542/10000
Epoch2:7976/10000
Epoch3:8283/10000
Epoch4:8632/10000
Epoch5:8632/10000
Epoch6:8652/10000
Epoch7:8443/10000
Epoch8:8671/10000
Epoch9:8669/10000
Test times 0: 8669/10000(正确识别个数/训练总数)

Process finished with exit code 0
```